

P1 HIGH-CAPACITY STRUCTURAL RESEARCH

Incumbent-preserving MS-TCN++/ASRF v2

고용량 장기 사전·경계 복구 모델의 사전등록 실행, 독립 QA 및 승격 판정

팀: 분당독고다이

실행: 2026-08-27 05:47:41–10:03:14 KST · 4시간 15분 33초

판정: **NO_GO_CONFIRMATORY** · 공식 제출/업로드 0회

계약: width 512 · epoch 125 · threshold 0.9 · 3-seed raw mean

결정 | 공식 제출 후보 기각

Q2의 +0.098157은 확인창에서 재현되지 않았다. Q4 false positive가 급증해 pooled ΔF1은 -0.005140이며, 새 전략은 다중 창 최악 성능과 추가행 precision을 직접 최적화해야 한다.

Pooled ΔF1	Q4 ΔF1	추가 precision	P(ΔF1>0)
-0.005140	-0.031484	38.11%	35.15%

독립 QA: 40/40 산출물 · 137 assertions PASS · 지표/게이트/bootstrap 재현

결론

이번 고용량 전략은 공식 제출 후보로 기각한다. Q2에서는 width 512·epoch 125·threshold 0.9가 Router 대비 $\Delta F1 +0.098157$ 로 선택됐지만, 이는 882개 격자의 고립된 낙관적 최대점이었다. 완전히 새로 적합한 확인창에서 Q3는 $+0.013299$ 개선됐으나 Q4가 -0.031484 로 붕괴해 pooled F1은 0.902917에서 0.897777로 -0.005140 하락했다.

추가한 753행의 pooled precision은 0.381142였다. incumbent-preserving OR가 기존 F1을 높이기 위한 최소 추가 precision 0.451459보다 7.03%p 낮다. 특히 Q4 추가 precision은 0.098930에 불과했다. 21일 block bootstrap CI90도 $[-0.028100, +0.014067]$ 로 0을 포함한다. 따라서 연구 성공과 high-impact 공식 probe gate가 모두 실패했으며 CSV 생성·공식 업로드·공식 +3 주장은 모두 0회다.

이 실패는 산출물 손상이나 계산 오류가 아니다. 독립 QA에서 40/40 산출물, 137개 무결성 assertion, Q3·Q4 지표와 10,000회 bootstrap 재계산이 모두 일치했다. 구조적 결론은 Q2 단일 최대점 선택과 전역 threshold를 통한 add-only 복구가 시기·station 변화에 견디지 못했다는 것이다.

목표와 기준선

공식 최고 P1 결과는 F1 0.817873, 문제 점수 28.492736이다. 같은 날 세 P1 제출의 점수 차로 계산한 공식 환산 기울기는 F1 1.0당 약 26.578036점이다. 따라서 현재 최고에서 3점을 더 얻으려면 F1 약 $+0.112875$, 즉 공식 F1 0.930748...가 필요하다. 실행 계약은 보수적으로 0.930749를 사용한다.

Q3+Q4 로컬 current-Router 기준선은 다음과 같다.

TP	FP	FN	F1	완전 FN 복구 상한
8,961	203	1,724	0.9029170235	0.9905900895

로컬 F1 0.930749까지 필요한 증가는 약 $+0.027832$ 다. 이는 계산상 가능하지만 공식 +3의 운송 증명은 아니다. 과거 Router 개선은 로컬 $+0.00222991$ 에 대해 공식 $+0.024163$ 으로 방향은 같았으나 크기 비율이 약 10.84배였다. 로컬과 공식의 절대 크기 대응은 안정적으로 보지 않는다.

전략 가설

현재 Router의 모든 양성은 그대로 유지한다. 새 모델은 2,048행 시간창에서 장기 사건 확률, 시작·종료 경계, 사건 유형을 함께 예측한다. 최종 후보는 아래처럼 단조 추가만 허용한다.

candidate = exact current Router OR decoded long-event proposal

따라서 기존 양성의 $1 \rightarrow 0$ 전이는 0이다. 개선 여부는 새로 추가한 행이 Router가 놓친 FN을 충분한 precision으로 복구하는지에 달려 있다.

모델과 계산 예산

공통 구조는 MS-TCN++에서 영감을 받은 dual-dilated prediction generator, 3개 local refinement stage, ASRF에서 영감을 받은 시작·종료 boundary head와 5개 anomaly-type head다. 입력은 fail-closed 감사를 통과한 165개 특징이다.

용량	Batch	학습 파라미터	측정 optimizer step	측정 peak VRAM
width 256	128	13,177,099	0.3360초	17.65 GiB
width 512	64	52,568,587	0.4705초	18.08 GiB

두 용량을 동시에 GPU에 올리지 않는다. Q2는 약 2.0–2.7시간, 전체 terminal 실행은 선택된 epoch와 width에 따라 약 3.7–8.3시간으로 예상된다. 300 epoch는 공식 구현을 재현하는 값이 아니라 수렴·적합 곡선을 관찰하기 위한 사전 고정 상한이다.

누수 방지와 특징 제약

전체 시계열 또는 미래 run 길이에 의존하는 다음 캐시 특징은 projection 단계에서 제거한다.

1. nominal_depth_m
2. depth_regime
3. plateau_full_length
4. plateau_count

depth regime은 현재 행 depth_raw와 각 학습 prefix에서만 적합한 threshold로 다시 계산한다. bounded centered feature의 최대 미래 support는 168시간, validation feature의 최대 과거 support는 169시간이다. 합계 337시간보다 긴 21일 10분 간격 purge를 적용하며 실제 최소 분리는 504.17시간이다. 특징 allowlist는 캐시 metadata 80개와 정확히 일치해야 하며 미분류 열은 자동 허용하지 않는다.

선택과 확인 절차

1. Q2 이전 prefix만 사용해 width 256/512 × seed 3개를 각각 300 epoch 완주한다.
2. epoch 1, 2, 3과 이후 5 epoch 간격의 총 63개 checkpoint에서 Q2 blind probability를 생성한다.
3. 각 width·epoch에서 3-seed 평균을 만들고 high threshold 0.3–0.9, low threshold high/2의 모든 후보를 Q2 truth 접근 전에 저장·해시 봉인한다.
4. Q2 truth를 한 번 열어 Router OR proposal F1로 width·epoch·threshold를 고른다. best seed 단독 선택은 금지한다.

5. 선택 사양을 고정하고 Q3와 Q4 prefix에서 각각 3개 seed를 새로 학습한다. 두 fold의 blind prediction을 모두 봉인한 뒤에만 두 truth를 연다.
6. Q3+Q4 pooled 지표와 fold-station별 부호, 두 fold를 합친 전역 KST 날짜 단위의 21일 paired circular block bootstrap 10,000회를 계산한다. 같은 날짜의 두 fold 행은 하나의 cross-section으로 함께 재표집한다.

Q3·Q4는 전역 달력 구간으로 완전히 분리된 fold가 아니다. 두 fold의 전역 envelope는 2025-10-01 하루에 19시간 50분 겹치지만, 두 fold가 모두 존재하는 16개 (station, year, layer) 시계열에서 Q3의 마지막 행과 Q4의 첫 행 사이 최소 간격은 10분이고 non-positive gap은 0이며 ordered row-key overlap도 0이다. 따라서 이를 series-local chronological/key-disjoint frozen folds로 명시한다. Q3 truth와 지표는 Q4 blind prediction까지 모두 봉인된 뒤에만 연다.

사전 고정 gate

Q2 연구 지속

5. Router-union $\Delta F1 \geq 0.010$
6. 추가 행 precision ≥ 0.70
7. eligible long-event Router-FN 회복률 ≥ 0.05
8. 후보 FP / Router FP ≤ 2.0
9. Router positive 제거 = 0

Q3+Q4 연구 성공

10. pooled $\Delta F1 \geq 0.015$
11. Q3, Q4 모두 $\Delta F1 > 0$
12. paired block-bootstrap CI90 lower > 0
13. Router positive 제거 = 0

공식 probe 검토 가능

14. pooled F1 ≥ 0.930749
15. pooled $\Delta F1 \geq 0.027832$
16. Q3, Q4 각각 $\Delta F1 \geq 0.010$
17. 추가 행 precision ≥ 0.75
18. 3개 station 중 최소 2개 개선


19. CI90 lower ≥ 0.015

20. Router positive 제거 = 0

이 gate의 명칭은 OFFICIAL_PROBE_ELIGIBLE이다. 공식 +3을 보장하거나 확인했다는 표현을 금지한다.

실행 결과

그림 1. 12개 학습 이력의 손실 곡선과 후반 불안정성



정식 launcher-only 단발 실행은 2026-08-27 KST 05:47:41부터 10:03:14까지 15,333.13초 수행됐다. 재시도는 없었고 Q2 6개 fit은 각 300 epoch, Q3-Q4 6개 refit은 각 125 epoch를 모두 완료했다. 12개 이력의 nonfinite 합은 0이다.

Q2 선택 전용 결과

선택 사양은 width 512, batch 64, epoch 125, high threshold 0.9, 3-seed raw probability 평균, 최소 추가 구간 19행, boundary snap 12행이다.


기준	Router	후보	차이/보조 지표
F1	0.792275574	0.890432823	+0.098157249
추가 행 precision	—	—	0.884220

기준	Router	후보	차이/보조 지표
long-event recall gain	—	—	+0.192401
FP 비율	—	—	1.298795×
Router 양성 제거	—	—	0행

그림 2. Q2 사양 선택 envelope와 epoch 125 고립 peak

Q2 유한 탐색의 epoch별 best $\Delta F1$

각 점은 사전 고정된 7개 threshold 중 최고 $\Delta F1$. epoch 125는 고립된 낙관적 peak로 취급하며 Q2는 selection-only임.



width 512의 Q2 최선 $\Delta F1$ 은 width 256 최선보다 +0.01849 높아 큰 용량을 시험한 선택 자체는 가치가 있었다. 그러나 epoch 125는 인접 epoch 120의 +0.071073, 130의 +0.078542보다 유난히 높은 +0.098157의 고립 peak였고, 882개 후보 중 유일한 최대점이다. 따라서 Q2는 사양 선택 증거일 뿐 승격 증거가 아니다.

Q3·Q4 확인 결과


구간	Router TP/FP/FN	후보 TP/FP/FN	Router F1	후보 F1	$\Delta F1$	추가 precision
Q3	5,241 / 74 / 1,156	5,491 / 203 / 906	0.894980	0.908279	+0.013299	0.659631
Q4	3,720 / 129 / 568	3,757 / 466 / 531	0.914342	0.882857	-0.031484	0.098930
Pooled	8,961 / 203 / 1,724	9,248 / 669 / 1,437	0.902917	0.897777	-0.005140	0.381142

OR 후보는 Router 양성 0행을 제거하지 않았고 FN 287행을 복구했지만 FP 466행을 추가했다. pooled 추가 precision 0.381142는 F1 개선에 필요한 Router F1/2 0.451459보다 낮다. Q4에서는 필요한 0.457171 대비 실제 0.098930으로, 성능 붕괴의 주된 원인은 Q4 false-positive 폭증이다.

Station	Router F1	후보 F1	$\Delta F1$
G-ORS	0.800962	0.831093	+0.030131
I-ORS	0.874434	0.870084	-0.004350

Station	Router F1	후보 F1	$\Delta F1$
S-ORS	0.935037	0.923869	-0.011168

그림 3. 확인창-station 별 효과와 사전 고정 gate



개선 station은 1/3이다. 163개 연속 KST 날짜를 대상으로 한 21일 paired circular moving-block bootstrap 10,000회에서 평균 $\Delta F1$ 은 -0.005624 , CI90은 $[-0.028100, +0.014067]$, 양수 replicate 비율은 35.15%였다. Q3-Q4 공유 날짜 1일은 pooled cross-section으로 한 번만 표집했다.

Gate와 수렴 판정

- 연구 성공: **FAIL** — pooled $\Delta F1$, Q4 부호, CI90 하한 실패.
- high-impact 공식 probe: **FAIL** — pooled endpoint $0.897777 < 0.930749$, $\Delta F1 -0.005140 < +0.027832$, 추가 precision $0.3811 < 0.75$, CI90 하한 $-0.02810 < 0.015$, 개선 station $1/3 < 2/3$.
- 공식 제출 후보: **아님**. submission 생성 0회, upload 0회, 공식 +3 주장 false.

Q3 refit의 final/min loss 배수는 $5.87\times$, $1.15\times$, $11.11\times$, Q4는 $12.60\times$, $1.00\times$, $26.54\times$ 였다. 모든 값은 유한했지만 선택 epoch 125의 최종 learning rate가 약 $1.99e-4$ 여서 여러 시드에 후반 최적화 상태 전이가 남았다. 따라서 “125 epoch에서 수렴했다”는 주장은 할 수 없다.

독립 QA

- 과학·통계 QA: $P0=0$ / $P1=0$ / $P2=1$; 지표·bootstrap·gate 재계산 일치. P2는 유한하지만 큰 tail-loss 불안정성이다.
- 무결성 QA: **PASS_CONTROLLED**, $P0=0$ / $P1=0$ / $P2=2$; exact inventory 40/40, 독립 assertion 137개 PASS. P2 두 건은 적대적 동일 프로세스/동시 경로 교체라는 기존 controlled-host 신뢰 경계다.
- terminal SHA-256:
7640cc0e29f364a26cd8199a7e9a55acd329699cd5923679d8f0d513c4af2b1

27. confirmatory metrics SHA-256:

964cae7d7dbb9f413244462eb9258e883e14f6073ad5549fadf482cb9cd03bd4

28. execution seal SHA-256:

2d42ce76966876f33daf0bd3e8e62051876f95f92e866588713bcfb84886bb25

다음 전략 목표

동일한 전역 threshold·단일 Q2 최대점 전략은 중단한다. 다음 후보는 아래 세 결함을 동시에 겨냥해야 한다.

- 다중 창 worst-fold 선택: 사전 고정된 최소 3개 historical development window에서 각 후보를 모두 평가하고, 평균이나 pooled 최고점이 아니라 $\min(\text{window } \Delta F1)$ 을 1차 목적함수로 삼는다. 모든 창에서 추가 precision이 적어도 해당 창 Router F1/2를 넘어야 하며, pooled F1은 동를 해소에만 사용한다. 이 규칙은 Q2 epoch 125와 같은 고립 peak가 다른 창의 손실을 가리고 선택되는 것을 막는다.
- precision-first abstention: add-only proposal을 즉시 OR하지 않는다. 과거 자료만으로 적합한 station-regime별 calibration과 causal support 조건을 통과한 구간만 추가하고, 표본이 부족하거나 precision 하한을 입증하지 못한 구간에서는 0개를 추가하는 abstention을 허용한다. 개발 단계의 최소 조건은 창별 추가 precision이 각 Router F1/2를 넘고, 3개 station 중 최소 2개에서 $\Delta F1$ 이 양수인 것이다. 공식 probe 검토에는 기존의 더 강한 pooled 추가 precision 0.75 기준을 그대로 유지한다.
- optimizer 안정화: 구조와 threshold 탐색을 다시 늘리기 전에 사전 고정된 더 낮은 learning-rate tail과 checkpoint/seed averaging을 비교한다. 선택 epoch의 단일 raw checkpoint가 아니라 동일한 다중 창 worst-fold 기준으로 안정화 방법 하나를 고르며, nonfinite 0뿐 아니라 tail-loss max/min, final/min, 창별 예측 변동도 함께 gate한다.
- 새 outer 확인창 보존: 이번 실행에서 Q2·Q3·Q4 결과가 모두 공개됐으므로 이후 이 창들은 진단·개발 자료일 뿐 새 승격 증거가 될 수 없다. 다음 승격 판정에는 아직 열지 않은 시간 구간을 outer holdout으로 남기거나, outer window가 매번 한 번만 열리는 nested forward-chaining 절차를 사용한다.

다음 실험의 핵심 질문은 “더 큰 모델인가”가 아니라 Q4와 같은 분포 변화에서도 추가 FP를 억제하면서 Router FN만 복구할 수 있는가다.

다음 실행의 승격 순서는 세 단계로 고정한다.

- 개발 지속: 모든 development window에서 $\Delta F1 > 0$, 추가 precision > 해당 Router F1/2, tail-loss 안정성 gate 통과.
- 연구 성공: 미사용 outer holdout에서 pooled $\Delta F1 \geq 0.015$, 모든 outer fold 양수, CI90 lower > 0, Router 양성 제거 0.

13. 공식 probe 검토: 기존 high-impact 기준 전체 통과 후에만 별도 사용자 승인을 요청한다. 로컬 통과만으로 공식 +3을 주장하지 않는다.

다음 실험에서 먼저 답할 질문

29. Q4의 FP 337행은 특정 station·regime·계절 구간에 집중됐는가, 아니면 전역 calibration 이동인가? 이 분석은 다음 abstention 규칙의 가설 생성에만 쓰고 Q3·Q4를 다시 확인창으로 재사용하지 않는다.
30. tail-loss 급등은 learning-rate schedule, temporal-smoothing 항, 희소 양성 batch 구성 중 무엇에 가장 민감한가? 한 번에 하나의 요인만 바꾸는 사전 고정 ablation으로 구분한다.
31. 다중 창에서 필요한 추가 precision 하한을 유지하면서도 공식 +3 목표에 필요한 recall 증가를 확보할 수 있는가? abstention이 안정성만 높이고 복구량을 지나치게 줄이든지도 함께 확인한다.
32. 완전히 미사용인 outer 확인 구간이 충분한가? 없다면 새 공식 제출 전에 검증 불확실성이 더 크다는 점을 명시하고, 공식 기회는 구조 검증용 probe로만 해석한다.

한계

33. MS-TCN++와 ASRF의 직접 실증 대상은 해양 QC가 아니라 비디오 동작 분할이다.
34. width 256/512와 300 epoch는 공식 MS-TCN++ 기본 설정보다 큰 외삽이다.
35. 3개 seed는 최소 안정성 점검이며 충분한 seed 불확실성 추정이 아니다.
36. Q3·Q4는 과거 분석에서 기준 점수가 알려진 retrospective window다. 이번 후보에 대해서만 prediction-before-truth 절차를 지킨다.
37. Q3·Q4의 전역 달력 envelope는 완전히 분리되지 않는다. 검증 독립성은 전역 분기 이름이 아니라 시계열별 엄격한 순서, exact-key disjointness, 두 fold를 함께 묶는 날짜 bootstrap에 의존한다.
38. 21일 block bootstrap은 시간 표본 변동을 다루지만 Q2 다중선택과 모든 HPO 불확실성을 포함하지 않는다.
39. official score transport는 관측점이 적고 과거 local/official 효과 크기가 크게 달랐다.

근거와 재현성

문헌의 직접 주장, 본 실험의 전이 추론과 적용 한계는 [주장·근거 원장](./claim-source-ledger.md)에 분리해 기록했다. 정량 결론의 기준 산출물은 terminal_result.json, confirmatory_metrics.json, q2_selection.json, 두 confirmatory blind receipt와 여섯 refit history다. 보고서의 주요 지표는 이 산출물에서 독립 재계산했으며, 위 SHA-256과 exact inventory 검증을 통과했다.

1차 문헌·구현 근거

아래 자료는 구조 선택의 근거다. 본 P1 데이터에서의 효과나 공식 +3점을 직접 입증하지 않는다.

[MS-TCN \(CVPR 2019\)](#)

[MS-TCN++ 논문](#)

[MS-TCN++ 공식 구현](#)

[ASRF 논문](#)

[시계열 검증 절차 연구](#)

[Benchmark variance 연구](#)

재현성 핵심 해시

산출물	SHA-256
terminal_result.json	7640cc0e29f364a26cd8199a7e9a55acdf329699cd5923679d8f0d513c4af2b1
confirmatory_metrics.json	964cae7d7dbb9f413244462eb9258e883e14f6073ad5549fadf482cb9cd03bd4
execution seal	2d42ce76966876f33daf0bd3e8e62051876f95f92e866588713bcfb84886bb25
selected recipe	171618200c69dc8e5039e5404bdeb4e7cb6369f15ab8ff43af1be7492837515a